

Analisi Predittiva e Backtesting Quantitativo su Serie Storiche Finanziarie (XAUUSD)

Progetto di Data Mining

Studente: Francesco Simbola

Anno Accademico: 2024/2025

Indice

1	Introduzione e Definizione del Problema	3
2	Data Understanding e Preprocessing	3
2.1	Normalizzazione Strutturale e Compressione Informativa	4
2.2	Analisi Esplorativa: Stagionalità e Volatilità Intraday	4
2.3	L'Integrità Temporale e l'Anomalia dei "Ghost Ticks"	5
2.4	Reindicizzazione a Blocchi e Risoluzione del Data Leakage	6
2.4.1	Segmentazione (Time-Series Segmentation)	6
2.4.2	Imputazione Intraday e Flat Doji	6
3	Feature Engineering e Baseline Model (Pattern Matching)	7
3.1	Vettorizzazione Spaziale (Sliding Windows)	7
3.2	Analisi Esplorativa delle Feature (EDA)	8
3.3	Proiezione Bidimensionale e Analisi della Sovrapposizione (PCA)	9
3.4	Costruzione del Modello Baseline: Cosine Similarity (K-NN)	10
3.4.1	Risultati del Baseline Model e Limiti Operativi	10
4	Modellazione Supervisionata: Ensemble Trees e Regressione	11
4.1	Split Cronologico (Out-of-Sample) e Future Leakage	11
4.2	Task 1: Classificazione Direzionale Binaria	11
4.2.1	Analisi dei Risultati di Classificazione	12
4.3	Task 2: Il Cambio di Paradigma con la Regressione (XGBRegressor)	12
5	Backtesting Quantitativo e Risk Management	12
5.1	Motore di Simulazione e Filtro Quantitativo	13
5.2	Analisi della Curva di Equity e Costi Commissionali	13
5.3	Signal Generation vs. Risk Management	14
6	Analisi Statistica e Valutazione dei Modelli	14
6.1	Analisi Esplorativa del Target (EDA)	14
6.2	Metriche di Classificazione (Random Forest vs XGBoost)	15
6.3	Analisi dell'Importanza delle Feature (Feature Importance)	15
6.4	Visualizzazione della Matrice di Confusione	16
6.5	Analisi dell'Errore nel Regressore (MAE)	18
7	Conclusioni e Sviluppi Futuri	18
7.1	Evoluzione dei Modelli e Feature Engineering	18
7.2	Risk Management e Strategia Operativa	19

1 Introduzione e Definizione del Problema

L'applicazione di algoritmi di Data Mining e Machine Learning alle serie storiche finanziarie rappresenta una delle sfide più complesse nell'ambito dell'analisi predittiva. A differenza dei classici dataset tabulari stazionari, i mercati finanziari sono caratterizzati da elevato rumore di fondo, non-stazionarietà e da una microstruttura dei prezzi soggetta a discontinuità sistematiche (es. chiusure dei mercati, assenza di liquidità).

Il presente progetto si pone l'obiettivo di sviluppare, ottimizzare e validare statisticamente un'architettura predittiva ad alta frequenza sul mercato dell'Oro (XAUUSD). L'analisi è condotta su un dataset storico a risoluzione *intraday* di un minuto (M1) relativo all'anno solare 2024.

Il problema affrontato trascende la semplice speculazione direzionale e si articola in tre task analitici fondamentali:

1. **Data Engineering e Integrità Temporale:** Trasformare i log grezzi estratti dai server dei broker (caratterizzati da tick persi, *look-ahead bias* da errata interpolazione e artefatti di fine settimana) in un tensore puramente numerico continuo, basato esclusivamente sul tempo effettivo di contrattazione (*Trading Time*).
2. **Estrazione di Pattern e Modellazione Supervisionata:** Passare da un approccio euristico basato su metriche di similarità (K-Nearest Neighbors/Cosine Similarity) all'addestramento di modelli *Ensemble Trees* (Random Forest, XGBoost) per catturare le asimmetrie spaziali delle formazioni grafiche. Il task si divide in Classificazione Binaria (previsione della direzione) e Regressione Continua (stima dell'escursione volumetrica).
3. **Validazione Finanziaria (Backtesting):** Valutare i modelli non solo tramite metriche accademiche standard (Accuracy, Precision, MAE), ma attraverso un motore di simulazione vettorializzato. Questo passaggio è cruciale per dimostrare l'assunto fondamentale della finanza quantitativa: un'accuratezza predittiva superiore al 50% non garantisce la profittabilità del sistema in presenza di costi commissionali (Spread) e variazioni di volatilità (*Risk:Reward Ratio*).

La tesi dimostrerà come l'integrazione di un filtro di tolleranza quantitativo (derivato dal regressore) permetta di mitigare i costi di transazione, isolando esclusivamente i pattern geometrici ad alta magnitudo e trasformando un semplice generatore di segnali in un framework decisionale realistico.

2 Data Understanding e Preprocessing

La preparazione del dato rappresenta il fondamento critico di questa pipeline analitica. Nelle serie storiche finanziarie ad alta frequenza, la qualità dell'informazione è sistemati-

camente degradata da anomalie di registrazione, formattazione incoerente e discontinuità temporali strutturali. Il processo di *Data Cleaning* è stato ingegnerizzato non solo per ripulire il dataset, ma per garantire l'assoluta assenza di *Data Leakage* (fuga di informazioni dal futuro al passato).

2.1 Normalizzazione Strutturale e Compressione Informativa

Il dataset di partenza (XAUUSD, anno 2024, timeframe M1) si presentava in un formato CSV grezzo estratto da piattaforma FXCM, caratterizzato da due problematiche primarie:

1. **Ambiguità dei Delimitatori:** L'utilizzo della virgola sia come separatore di colonna sia come separatore decimale per i prezzi generava un disallineamento della matrice. Un primo algoritmo (`1Converter.py`) è stato sviluppato per parsare le stringhe, isolare la radice intera dalla mantissa decimale e forzare una struttura costante a 19 colonne.
2. **Compressione Bid/Ask:** I dati originali presentavano una doppia quotazione per ogni minuto (OHLC Bid e OHLC Ask). Per addestrare i modelli regressivi su una curva di valore univoca, è stato calcolato il *Mid-Price* (media aritmetica tra Bid e Ask), neutralizzando le fluttuazioni transitorie dello spread e isolando il vero *Fair Value* dell'asset. I prezzi sono stati infine arrotondati a due decimali (centesimi di dollaro).

2.2 Analisi Esplorativa: Stagionalità e Volatilità Intraday

Al fine di comprendere le dinamiche strutturali dell'asset XAUUSD prima di procedere alla pulizia del dato, è stata condotta un'analisi esplorativa (EDA) sulla volatilità intraday. Utilizzando la deviazione standard del conteggio dei tick come indicatore di attività, è emersa una marcata ciclicità legata agli orari operativi delle piazze finanziarie globali.

Come illustrato in Figura 1, il mercato dell'oro attraversa regimi di liquidità profondamente diversi nell'arco delle 24 ore.




Figura 1: Volatilità intraday dell’oro misurata tramite la deviazione standard dei tick per fascia oraria. Si evidenzia l’alternanza tra la fase di contrazione asiatica e l’espansione dei volumi durante la sessione americana.

Il grafico evidenzia un fisiologico calo dei volumi durante le ore notturne europee (es. picco di minima attività tra le 03:00 e le 04:00), contrapposto a un drastico incremento dell’attività a partire dalle ore 13:00. Questa impennata di volatilità coincide con la pre-apertura della sessione di New York e con il consueto orario di rilascio dei principali dati macroeconomici statunitensi. Questa marcata eterogeneità dei regimi di mercato conferma l’assoluta necessità di un filtro quantitativo a valle dei modelli predittivi, indispensabile per evitare l’operatività durante le fasi di stallo in cui il rumore di fondo e lo *spread* annullerebbero qualsiasi vantaggio statistico.

2.3 L’Integrità Temporale e l’Anomalia dei “Ghost Ticks”

La sfida ingegneristica più complessa ha riguardato la gestione dei gap temporali. L’approccio accademico standard prevede la creazione di un indice temporale continuo dal primo all’ultimo giorno dell’anno (*Calendar Time*), riempiendo i buchi tramite funzioni di imputazione.

L’applicazione di questa logica ha portato all’individuazione di un’anomalia critica: l’iniezione dei cosiddetti “**Ghost Ticks**”. Analizzando l’output dell’algoritmo, si è notato che il dataset conteneva centinaia di registrazioni anomale durante il fine settimana (es. 1.440 candele generate di sabato). Queste derivavano dai server del broker che, durante le fasi di manutenzione a mercati chiusi, ripetevano in loop l’ultimo prezzo di chiusura del venerdì. Mantenendo il dataset ancorato al tempo di calendario, il modello di Machine Learning identificava queste lunghe fasi piatte e generava operazioni virtuali, falsando i risultati del backtest (che registrava profitti irreali in giorni in cui il mercato non esisteva).

2.4 Reindicizzazione a Blocchi e Risoluzione del Data Leakage

Per eliminare i Ghost Ticks e gestire i micro-gap fisiologici intraday (es. tick persi per cali di liquidità), l'architettura è stata riscritta abbandonando il *Calendar Time* in favore del *Trading Time*.

2.4.1 Segmentazione (Time-Series Segmentation)


Invece di forzare la continuità sull'intero anno solare, l'algoritmo calcola i differenziali temporali tra ogni candela. Qualora il gap superi le 12 ore (identificando deterministicamente la chiusura del weekend o le festività globali), il punto viene utilizzato per “tagliare” il dataset. La reindicizzazione al singolo minuto avviene esclusivamente all'interno di questi blocchi operativi attivi. In questo modo, la candela immediatamente successiva alle 23:59 del venerdì è esattamente quella di riapertura della domenica notte, eliminando fisicamente il weekend dal dataset e riducendo la dimensionalità della matrice di circa 150.000 righe.

2.4.2 Imputazione Intraday e Flat Doji

Per i micro-gap interni ai blocchi operativi continui ($\text{gap} < 5$ minuti), l'approccio iniziale prevedeva l'uso dell'interpolazione lineare. Tuttavia, un'attenta analisi ha rivelato che tale tecnica introduce **Data Leakage**: per creare una coesione di prezzo tra due tick distanti, la funzione matematica utilizza il prezzo di riapertura (un dato del futuro) per calcolare il valore dei minuti mancanti nel passato.

Si è optato per un approccio basato sul *Forward Fill*: le candele mancanti sono state generate propagando in avanti esclusivamente l'ultimo prezzo di chiusura noto. Il risultato è la creazione di **Flat Doji** (candele piatte con $\text{Open} = \text{High} = \text{Low} = \text{Close}$ e $\text{Volume} = 0$). Questa soluzione (illustrata in Figura 2) informa correttamente l'algoritmo che il mercato è rimasto illiquido o fermo in quel lasso temporale, preservando la rigorosa separazione tra passato e futuro.

Candela Standard Rialzista



Imputazione
(*Forward Fill*)

Flat Doji (Micro-gap)

Open = High = Low = Close
Volume = 0

Figura 2: Rappresentazione geometrica di una candela standard rialzista (OHLC) confrontata con una candela *Flat Doji* generata alitmicamente per preservare l'integrità temporale senza introdurre Data Leakage.

3 Feature Engineering e Baseline Model (Pattern Matching)

Risolto il problema dell'integrità strutturale e temporale, la pipeline affronta la trasformazione del dato. I prezzi assoluti di un asset finanziario sono intrinsecamente non-stazionari (variano nel tempo senza una media fissa). Utilizzare direttamente i prezzi grezzi in un modello predittivo ridurrebbe la sua capacità di generalizzazione.

L'obiettivo di questa fase è trasformare la serie storica in un set di feature stazionarie, focalizzate esclusivamente sulla *geometria* e sul *momentum* del mercato.

3.1 Vettorizzazione Spaziale (Sliding Windows)

Il paradigma adottato si basa sull'astrazione geometrica della candela giapponese (OHLC). Per ogni singolo periodo, la struttura dei prezzi è stata scomposta in quattro componenti spaziali relative:

- **Body (Corpo):** $Close - Open$. Indica la forza e la direzione (segno) del movimento netto.
- **Range (Escursione Totale):** $High - Low$. Misura la volatilità assoluta del singolo minuto.
- **Upper Shadow (Ombra Superiore):** Distanza tra il Massimo e il maggiore tra Open e Close. Rappresenta la pressione di vendita (rigetto rialzista).
- **Lower Shadow (Ombra Inferiore):** Distanza tra il Minimo e il minore tra Open e Close. Rappresenta la pressione di acquisto (rigetto ribassista).

Per catturare la sequenzialità temporale dei pattern, è stata implementata una tecnica di **Sliding Window** (finestra mobile). È stata definita una finestra di profondità pari a $w = 10$, dove le prime 9 candele (36 feature spaziali) costituiscono il vettore di *input* (X), mentre la 10^a candela rappresenta il *target* spaziale da prevedere (Y).

Per garantire un allineamento rigoroso per la fase di backtest, le matrici sono state estratte estrapolando simultaneamente:

- Y_{class} : Vettore binario (0 per rialzo, 1 per ribasso) per il task di classificazione direzionale.
- Y_{reg} : Vettore continuo rappresentante il *Body* effettivo in dollari della candela futura, necessario per l'applicazione del filtro quantitativo.

3.2 Analisi Esplorativa delle Feature (EDA)

Per comprendere la natura stocastica del mercato *intraday* e giustificare la successiva architettura dei modelli, è stata condotta un'analisi esplorativa (EDA) sulle feature geometriche estratte.

La Figura 3 mostra la distribuzione di due feature chiave: il *Body* (direzione e impulsività netta) e il *Range* (volatilità assoluta del singolo minuto). Per ragioni di chiarezza visiva e per apprezzare la reale conformazione della densità dei dati, gli assi orizzontali sono stati limitati escludendo i rari *outlier* macroeconomici (es. picchi di volatilità superiori a 5 punti), concentrando l'analisi sul 99° percentile della distribuzione.




Figura 3: Distribuzione del Body e del Range. Si nota la fortissima concentrazione dei dati attorno allo zero (Body) e un picco di volatilità media inferiore a 0.5 punti (Range). Questa ristrettezza dei margini operativi evidenzia il peso critico dello spread commissionale.

L'analisi visiva conferma che la maggior parte delle candele presenta un corpo netto inferiore a 1 punto, con una volatilità totale (Range) che ha il suo picco di frequenza tra 0.3 e 0.5 punti. Questo dato empirico è fondamentale: considerando un costo di spread medio di 0.15 punti per transazione, operare indiscriminatamente su timeframe così ristretti comporta un tasso di erosione del capitale matematicamente insostenibile.

3.3 Proiezione Bidimensionale e Analisi della Sovrapposizione (PCA)

A completamento dell'indagine esplorativa, e per valutare la separabilità lineare del dataset, è stato applicato un algoritmo di *Feature Extraction*. Tramite **Principal Component Analysis (PCA)**, le 36 feature spaziali relative al passato (*Sliding Window*) sono state compresse in due sole dimensioni (Componenti Principali).

L'obiettivo della proiezione, illustrata in Figura 4, è verificare se i pattern antecedenti a un movimento rialzista (Classe 0) e ribassista (Classe 1) formino dei *cluster* distinti nello spazio vettoriale.




Figura 4: Proiezione PCA a 2 dimensioni del Training Set. L'assoluta sovrapposizione cromatica dimostra l'impossibilità di tracciare un iperpiano di separazione lineare tra le due classi direzionali.

Il risultato della PCA evidenzia una nuvola di punti densa, omogenea e con una sovrapposizione cromatica totale tra le due classi. Questo scatter plot dimostra visivamente

l'ipotesi di Efficienza del Mercato a brevissima latenza: dal solo punto di vista geometrico, le conformazioni storiche che precedono un rialzo sono statisticamente indistinguibili da quelle che precedono un ribasso. Tale sovrapposizione fornisce la motivazione teorica per cui i successivi classificatori (*Random Forest* e *XGBoost*) faticano a generare un vantaggio statistico netto sulla sola previsione direzionale, assestandosi su un'accuratezza limite del 50%.

3.4 Costruzione del Modello Baseline: Cosine Similarity (K-NN)

Prima di implementare algoritmi di Machine Learning supervisionato, è stato sviluppato un *Baseline Model* per testare l'ipotesi euristica alla base del progetto originale: "Pattern storici simili producono risultati futuri simili".

È stato implementato un algoritmo di pattern matching assimilabile a un *1-Nearest Neighbor* iterativo, basato sulla **Similarità del Coseno** (Cosine Similarity). L'algoritmo calcola l'angolo normalizzato tra il vettore della finestra corrente (il mercato attuale) e tutti i vettori storici archiviati nel *Training Set*. La funzione di similarità tra due vettori A e B è definita come:

$$\text{Similarity}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (1)$$

3.4.1 Risultati del Baseline Model e Limiti Operativi

L'algoritmo scansiona lo storico per identificare il pattern con la similarità angolare più elevata rispetto al mercato reale (ad esempio, $\cos(\theta) > 0.98$). Una volta individuato il *best match*, il modello predice che la candela successiva seguirà la stessa polarità osservata storicamente.

I test esplorativi condotti tramite Cosine Similarity hanno tuttavia evidenziato i limiti computazionali e statistici dell'approccio *Lazy Learning* ad alta frequenza. Sebbene capace di isolare pattern visivamente identici, il modello assegna un peso lineare a tutte le feature vettorializzate, risultando altamente vulnerabile al rumore di fondo (tipico del timeframe M1). L'inadeguatezza dell'algoritmo geometrico di base nel filtrare i segnali deboli in presenza di attriti commissionali ha reso necessario il passaggio all'addestramento di modelli predittivi non lineari (Ensemble Trees).

4 Modellazione Supervisionata: Ensemble Trees e Regressione

Le limitazioni del Baseline Model nel gestire il rumore di fondo ad alta frequenza hanno motivato l'adozione di algoritmi di Machine Learning supervisionato basati su architetture non-lineari. Nello specifico, la famiglia degli *Ensemble Trees* si rivela particolarmente adatta per le serie storiche finanziarie, in quanto capace di gestire relazioni complesse tra le feature spaziali (ombre e corpi delle candele) senza richiedere assunzioni di normalità distributiva.

4.1 Split Cronologico (Out-of-Sample) e Future Leakage

Per addestrare e validare i modelli, il dataset vettorializzato è stato suddiviso in due partizioni: un *Training Set* (80% dei dati) e un *Testing Set* (20%). Contrariamente alle metodologie classiche di classificazione (es. *K-Fold Cross Validation* o campionamento casuale), è stato applicato un rigoroso **Split Cronologico**. Nel contesto del Data Mining finanziario, randomizzare l'ordine dei sample causerebbe *Future Leakage*, permettendo al modello di addestrarsi su pattern cronologicamente successivi a quelli che è chiamato a prevedere. L'ultimo 20% dell'anno 2024 è stato quindi isolato e mantenuto inaccessibile durante la fase di *fit*, garantendo un test *Out-of-Sample* puro.

4.2 Task 1: Classificazione Direzionale Binaria

Il primo approccio di modellazione ha affrontato un task di classificazione binaria per prevedere esclusivamente la polarità della candela successiva (0 = Rialzista/Long, 1 = Ribassista/Short).

Nota sul Preprocessing (Normalizzazione e Outlier): Essendo stati selezionati modelli *Ensemble* non-lineari basati su alberi decisionali, non si è resa necessaria alcuna fase di Normalizzazione o Standardizzazione delle feature spaziali. Tali architetture effettuano split decisionali basati sull'ordinamento (ranking) dei valori e risultano intrinsecamente invarianti rispetto alla scala delle grandezze, oltre che robusti contro gli outlier fisiologici (picchi di volatilità) del mercato. Sono stati addestrati due modelli comparativi:

- **Random Forest Classifier:** Un algoritmo di *Bagging* che costruisce una moltitudine di alberi decisionali de-correlati, riducendo la varianza e mitigando l'overfitting.
- **XGBoost Classifier (Extreme Gradient Boosting):** Un algoritmo di *Boosting* che ottimizza sequenzialmente gli alberi minimizzando una funzione di perdita (es. *LogLoss*).

4.2.1 Analisi dei Risultati di Classificazione

L'addestramento sui dati preprocessati (esclusione dei *Ghost Ticks* del weekend e del *Data Leakage* da interpolazione) ha restituito un'Accuracy predittiva su dati Out-of-Sample pari a circa il **50.3%** per entrambi i modelli. Da un punto di vista accademico, questo risultato rappresenta un traguardo diagnostico fondamentale: dimostra che il dataset è ora privo di pattern artificiali ripetitivi. Su un timeframe a 1 minuto (M1), le fluttuazioni direzionali dell'Oro approssimano un *Random Walk* (passeggiata casuale). Prevedere unicamente la direzione (su/giù) in un contesto così rumoroso equivale a lanciare una moneta, rendendo i classificatori direzionali puri inefficaci per un'applicazione finanziaria reale.

4.3 Task 2: Il Cambio di Paradigma con la Regressione (XGBRegressor)

I limiti della classificazione pura hanno motivato un'evoluzione architetturale del progetto. Nel trading algoritmico, conoscere la direzione del mercato è inutile se l'escursione del prezzo non è sufficiente a coprire i costi di transazione (Spread).

L'obiettivo predittivo è stato quindi mutato da qualitativo (direzione) a quantitativo (impulsività). È stato implementato un modello **XGBoost Regressor**, addestrato non più per prevedere etichette binarie, bensì per stimare l'escursione esatta in punti base (il *Body* continuo) della decima candela. Il modello regressivo minimizza l'errore assoluto (MAE - *Mean Absolute Error*), risultando intrinsecamente conservativo: in presenza di rumore direzionale, l'algoritmo regredisce verso lo zero, prevedendo candele di ampiezza trascurabile.

Questa caratteristica quantitativa pone le basi per il modulo finale del progetto: l'implementazione di un filtro di tolleranza. Il regressore non funge più solo da predittore, ma da *indicatore di liquidità*, permettendo al motore di simulazione di scartare le operazioni in cui la volatilità attesa risulta inferiore alla soglia di profittabilità netta.

5 Backtesting Quantitativo e Risk Management

Visti i risultati, una previsione temporalmente e direzionalmente corretta può trasformarsi in una perdita monetaria se non si considerano i costi di commissione del mercato reale. Per questo motivo, l'ultimo step della pipeline consiste nell'implementazione di un motore di simulazione di portafoglio (*Backtesting*).

5.1 Motore di Simulazione e Filtro Quantitativo

L'architettura del simulatore è stata progettata per processare il segmento *Out-of-Sample* (il 20% finale del dataset, pari a circa 70.900 candele) traducendo i segnali del modello in un'*Equity Curve* monetaria. I parametri operativi sono stati standardizzati: capitale iniziale di \$10.000, size fissa di 0.1 lotti (con un moltiplicatore di \$10 per ogni punto di movimento dell'Oro) e uno spread costante stimato a 0.15 punti per transazione.

Invece di operare indiscriminatamente su ogni candela, il sistema ha sfruttato le stime di impulsività fornite dall'XGBoost Regressor per implementare un **Filtro di Soglia Operativa**: l'algoritmo esegue un trade (Long o Short) esclusivamente se il movimento assoluto previsto è superiore a 0.20 punti. In caso contrario, il sistema interpreta il mercato come laterale (o eccessivamente rumoroso) e si astiene dall'operare.

5.2 Analisi della Curva di Equity e Costi Commissionali

L'esecuzione del backtest sul dataset strutturalmente purificato ha prodotto risultati illuminanti sotto il profilo quantitativo. Il filtro di tolleranza ha dimostrato un'eccellente capacità di scrematura: il sistema ha ignorato il mercato nel 94.5% del tempo, filtrando il rumore di fondo ed eseguendo “soltanto” 3.897 trade operativi.

Nonostante l'alta selettività, l'*Equity Curve* generata (Figura 5) mostra un deterioramento progressivo del capitale, chiudendo la simulazione con un drawdown del 61.77% e un Win Rate netto del 43.67%.




Figura 5: Equity Curve del modello XGBRegressor (Out-of-Sample). Il deterioramento è costante e privo di anomalie algoritmiche (es. *Ghost Ticks*), riflettendo le reali condizioni di mercato intraday.

Il risultato negativo non è imputabile a un fallimento predittivo del modello, bensì all'impatto dei costi di transazione. Eseguendo 3.897 operazioni con uno spread di 0.15

punti, l'algoritmo ha pagato al broker circa 584.5 punti totali, equivalenti a **\$5.845 di costi di transazione**. Considerando che la perdita netta finale ammonta a circa \$6.176, si evince che il modello di Machine Learning ha generato un PnL (Profit and Loss) lordo sostanzialmente in pareggio, ma l'aspettativa matematica è stata erosa dai costi di spread, impossibili da superare sistematicamente su timeframe così brevi (M1).

5.3 Signal Generation vs. Risk Management

L'esperimento quantitativo certifica un principio fondamentale del trading algoritmico: un modello di Machine Learning funge esclusivamente da *Signal Generator*, ma è inefficace se non incapsulato in un framework di *Risk Management*.

L'attuale logica di simulazione opera "semplice": entra all'apertura del minuto e chiude alla fine del minuto, a prescindere dall'escursione del prezzo. L'assenza di un limite massimo alla perdita per singola operazione (Stop Loss) espone il sistema ai *Black Swans* o ai picchi di volatilità indotti dalle notizie macroeconomiche. Di conseguenza, il rapporto Rischio/Rendimento risulta svantaggioso: le vincite sono limitate alle piccole escursioni intraday, mentre le singole perdite possono assorbire i profitti di decine di operazioni corrette.

Pur non avendo prodotto un Trading System profittevole *out-of-the-box*, l'integrazione tra la regressione Ensemble e il filtro quantitativo ha gettato le basi per una buona infrastruttura. I futuri sviluppi richiederanno la migrazione verso dataset *Tick-by-Tick* (necessari per simulare il percorso intra-candela) e l'integrazione di regole di *Money Management* per assecondare la volatilità prevista dal modello.

6 Analisi Statistica e Valutazione dei Modelli

Prima della fase di addestramento, è stata condotta un'analisi approfondita sulle performance predittive dei modelli *Out-of-Sample*. La validazione su un campione di 70.907 candele future ha permesso di quantificare oggettivamente la capacità di generalizzazione degli algoritmi, isolando il potere predittivo dal rumore stocastico.

6.1 Analisi Esplorativa del Target (EDA)

L'ispezione della distribuzione delle classi nel Testing Set evidenzia un bilanciamento quasi perfetto: 36.165 candele con polarità rialzista (51%) e 34.742 candele con polarità ribassista (49%). Questa simmetria distributiva conferma empiricamente l'ipotesi di efficienza del mercato sul brevissimo termine: in assenza di macro-trend multi-orari, la probabilità che il prezzo salga o scenda nel minuto successivo si attesta statisticamente attorno al 50%, configurando il mercato M1 come un *Random Walk* e definendo il *Baseline Accuracy* teorico al 50.9%.

6.2 Metriche di Classificazione (Random Forest vs XGBoost)

L'addestramento dei due classificatori ad albero ha richiesto tempi computazionali nettamente differenti: 13.79 secondi per il Random Forest contro gli 0.86 secondi dell'XGBoost, evidenziando la superiore efficienza dell'architettura a gradiente.

Nonostante le differenze architettureali, entrambi i modelli hanno restituito metriche di accuratezza globale sovrapponibili (Tabella 1), confermando che il limite predittivo non risiede nella complessità del modello, bensì nell'intrinseca casualità dei dati.

Modello	Accuracy	Precision (Weighted)	Recall (Weighted)	F1-Score (Rialzista)	F1-Score (Ribassista)
<i>Random Forest</i>	50.39%	50.00%	50.00%	0.56	0.43
<i>XGBoost</i>	50.33%	50.00%	50.00%	0.55	0.44

Tabella 1: Confronto delle metriche di classificazione *Out-of-Sample* (Test Set = 70.907 sample). L'inclusione delle metriche ponderate (*Weighted*) conferma la difficoltà del modello nell'estrarre un vantaggio statistico netto rispetto a una distribuzione stocastica (50/50).

6.3 Analisi dell'Importanza delle Feature (Feature Importance)

Per indagare ulteriormente le dinamiche decisionali dell'algoritmo e le ragioni dell'accuratezza limite al 50%, è stata estratta la *Feature Importance* dal modello XGBoost (Figura 6).




Figura 6: Top 15 Feature Importance (XGBoost Classifier). La distribuzione dei pesi risulta piatta e omogenea (attorno al 2.6% per ogni feature), evidenziando l'assenza di un predittore geometrico dominante.

L'istogramma rivela una distribuzione dei pesi pressoché uniforme. In un contesto predittivo deterministico, ci si aspetterebbe una curva asimmetrica in cui le candele più recenti (es. Candela 10) detengono un potere informativo nettamente superiore. Al contrario, il modello assegna un'importanza quasi identica a componenti spaziali distanti e scorrelate (es. *Body* della Candela 10 vs *Range* della Candela 7). Questa frammentazione del peso decisionale rappresenta la conferma algoritmica finale dell'ipotesi di Efficienza del Mercato a un minuto: in assenza di pattern latenti dominanti, il classificatore non è in grado di selezionare una feature chiave, ripiegando su un'assegnazione stocastica che giustifica le prestazioni paragonabili al puro lancio della moneta.

6.4 Visualizzazione della Matrice di Confusione

Per analizzare il comportamento dell'algoritmo nei falsi segnali, è stata generata la Matrice di Confusione relativa al modello XGBoost (Figura 7).

		Classe Prevista	
		Rialzista (0)	Ribassista (1)
Classe Reale	Rialzista (0)	Vero Rialzista 21.821 (30.7%)	Falso Ribassista 14.344 (20.2%)
	Ribassista (1)	Falso Rialzista 20.875 (29.4%)	Vero Ribassista 13.867 (19.5%)

Figura 7: Matrice di Confusione (XGBoost Classifier). Il modello manifesta una leggera asimmetria (bias) verso la previsione rialzista, come evidenziato dall'elevato numero di Falsi Rialzisti.

L'analisi della matrice rivela che il modello fatica a identificare le inversioni ribassiste (elevato tasso di *Falsi Rialzisti*), tendendo a sovrastimare la continuazione del trend long. Questo comportamento, unito a una *Accuracy* prossima al limite teorico del lancio della moneta, ha reso indispensabile il passaggio al modello di regressione.

Di seguito vediamo le metriche prestazionali dei due classificatori messe a confronto tramite una visualizzazione a barre (Figura 8).




Figura 8: Confronto grafico delle prestazioni (*Accuracy* e *F1-Score Macro*) tra Random Forest e XGBoost sul Test Set. La linea tratteggiata rossa evidenzia la soglia teorica del 50% (Random Walk), mostrando visivamente il limite predittivo direzionale su questo orizzonte temporale (M1).

Il grafico evidenzia in modo immediato come, nonostante le differenze architetturali tra *Bagging* (Random Forest) e *Boosting* (XGBoost), i due modelli restituiscano risultati pressoché identici. Entrambi si infrangono contro la soglia rossa del 50%, confermando quanto avevamo già dedotto visivamente dalla proiezione PCA: prevedere la pura direzione su un orizzonte di un minuto è statisticamente analogo al lancio di una moneta.

Per validare quantitativamente l'impatto della riduzione di dimensionalità, il modello *XGBoost Classifier* è stato riaddestrato esclusivamente sulle 2 Componenti Principali estratte.

La valutazione *Out-of-Sample* sui dati compressi ha restituito un'Accuracy praticamente identica (**50.34%** contro il **50.33%** delle feature originali). Questo risultato empirico certifica che la compressione spaziale (*Feature Extraction*) non è in grado di isolare alcun pattern discriminatorio. L'impossibilità di superare la soglia del Random Walk, sia su 40 dimensioni spaziali che sulla loro sintesi bidimensionale, conferma in via definitiva l'inefficacia della classificazione direzionale pura in un mercato ad alta latenza, imponendo e giustificando la transizione tecnica verso l'architettura regressiva con filtro quantitativo.

6.5 Analisi dell'Errore nel Regressore (MAE)

L'addestramento dell'XGBoost Regressor ha restituito un **Errore Medio Assoluto (MAE)** di 0.4363 punti sull'escursione della candela, associato a un'*Accuracy Direzionale* calcolata sulla derivata del 50.75%. Da un punto di vista finanziario, un MAE di ≈ 0.44 punti significa che il modello sbaglia in media la previsione dell'ampiezza della candela di circa 4.4 PIPs. Considerando che lo spread medio pagato al broker è di 0.15 punti (1.5 PIPs), il margine di errore del modello è quasi tre volte superiore al costo di transazione. Questa discrepanza statistica spiega matematicamente l'incapacità del sistema *unfiltered* di generare un profitto netto costante nel simulatore di portafoglio, motivando l'introduzione del filtro selettivo a 0.2 punti analizzato nel backtest.

7 Conclusioni e Sviluppi Futuri

Il presente progetto ha delineato e risolto le criticità strutturali intrinseche al Data Mining finanziario ad alta frequenza. Si è dimostrato empiricamente come una rigorosa *Data Engineering* focalizzata sull'eliminazione dell'interpolazione lineare, sul passaggio al *Trading Time* e sulla generazione di candele causali (*Flat Doji*), sia il prerequisito fondamentale per neutralizzare il *Data Leakage* ed evidenziare l'ottimizzazione ingannevole derivante dagli artefatti del server (es. *Ghost Ticks*).

L'analisi ha confermato che la microstruttura dei prezzi a un minuto (M1) approssima un *Random Walk*. Tuttavia, l'evoluzione dell'architettura predittiva da un semplice classificatore direzionale a un *Ensemble Regressor* dotato di filtro quantitativo ha dimostrato che è possibile isolare le inefficienze volumetriche, scartando matematicamente oltre il 94% del rumore di fondo.

Pur avendo costruito un'infrastruttura di analisi istituzionale, il sistema non ha prodotto un *Trading System* profittevole. Questo esito negativo è da imputarsi alle attuali limitazioni che tracciano la strada per i futuri sviluppi del progetto, riassumibili in due macro-aree:

7.1 Evoluzione dei Modelli e Feature Engineering

L'approccio attuale si basa su *Sliding Windows* statiche che valutano esclusivamente la geometria delle ultime candele. Sebbene utile come *baseline*, questa astrazione spaziale non cattura completamente le dinamiche del mercato:

- **Modelli Sequenziali:** Il passaggio da architetture ad albero (Random Forest/XGBoost) a Reti Neurali Ricorrenti (es. LSTM) o architetture *Transformer* permetterebbe di analizzare la serie storica come un continuum temporale, catturando le dipendenze a lungo termine e pattern di volatilità storici che sfuggono alle metriche spaziali.

- **Integrazione di Dati Multi-Dimensionali:** Il modello necessita di ulteriori *feature* esterne al mero prezzo. L'integrazione di indicatori di *momentum* (es. RSI, MACD), metriche di *Order Flow* (pressione reale di acquisto/vendita) e dati *Tick-by-Tick* fornirebbe all'algoritmo il contesto di mercato necessario per validare un segnale geometrico.

7.2 Risk Management e Strategia Operativa

La lacuna più critica dell'attuale pipeline risiede nell'assenza di una vera e propria strategia di *Money e Risk Management*. L'algoritmo attuale non applica regole avanzate di gestione della posizione: entra a mercato all'apertura del minuto, esce matematicamente alla sua chiusura e non possiede alcuna gestione del rischio asimmetrico.

- **Gestione del Trade e Holding Period:** Imporre la chiusura fissa dopo 60 secondi (un minuto) preclude la possibilità di capitalizzare sui veri trend direzionali. Un sistema avanzato dovrebbe prevedere condizioni di uscita logiche e dinamiche, mantenendo la posizione aperta finché le probabilità a favore persistono.
- **Stop Loss e Take Profit Dinamici:** L'implementazione di uno *Stop Loss* basato sulla volatilità corrente (es. multipli dell'ATR - *Average True Range*) è fondamentale per limitare le perdite in caso di eventi estremi (i *Black Swans*). Parallelamente, un *Trailing Stop* permetterebbe di far correre i profitti riducendo l'impatto negativo dello spread.
- **Position Sizing:** La dimensione della posizione (attualmente fissa a 0.1 lotti) dovrebbe essere modulata dinamicamente in base alla magnitudo prevista dall'XGBoost Regressor e all'ammontare del capitale disponibile, applicando criteri matematici come il *Criterio di Kelly* per ottimizzare l'aspettativa di crescita a lungo termine.

In conclusione, il lavoro svolto ha trasformato una fragile euristica di *pattern matching* in una pipeline di Data Science completamente funzionante. Incapsulando i modelli di regressione sviluppati all'interno di un reale framework di gestione del rischio, l'infrastruttura è pronta per superare il problema commissionale ed evolversi in un sistema di trading quantitativo completo.